

线性代数方程组

浙江大学控制学院

本章内容

- 高斯消去法
- LU分解、特殊矩阵和矩阵求逆
- 误差分析、条件数
- 迭代方法

误差分析和方程组条件数

- 利用逆矩阵确定方程组是否病态的方法
 - 缩放系数矩阵 A ，使其每一行的最大元素为1。计算缩放后的逆矩阵，如果 A^{-1} 中有元素的值大于1几倍，则方程组是病态的。
 - 将逆矩阵与原矩阵相乘，检查结果是否接近单位阵。如果不接近单位阵，则方程组是病态的。
 - 求逆矩阵的逆矩阵，与原系数矩阵对比。如果不相等，则方程组是病态的。

向量和矩阵的范数

- 向量的范数

- 三维欧氏空间中向量长度概念的推广
- 定义

设对任意向量 $x \in R^n$, 按一定的规则有一实数与之对应, 记为 $\|x\|$, 若 $\|x\|$ 满足

1, $\|x\| \geq 0$, 且 $\|x\| = 0$ 当且仅当 $x = 0$; (正定)

2, $\|\alpha x\| = |\alpha| \cdot \|x\|$, α 为任意实数 (齐次)

3, $\|x + y\| \leq \|x\| + \|y\|$, 对任意 $x, y \in R^n$

(三角不等式)

则称 $\|x\|$ 为 向量 x 的范数

向量和矩阵的范数

- 几种向量范数

- 向量的“2”范数
(欧几里德范数)

$$\|x\|_2 = \sqrt{x_1^2 + \cdots + x_n^2} = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}$$

- 向量的“1”范数

$$\|x\|_1 = |x_1| + \cdots + |x_n| = \sum_{i=1}^n |x_i|$$

- 向量的“ ∞ ”范数
(极大值范数或一致向量范数)

$$\|x\|_\infty = \max\{|x_1|, \cdots, |x_n|\} = \max_{1 \leq i \leq n} \{|x_i|\}$$

- 向量的“ p ”范数

$$\|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

向量和矩阵的范数

● 矩阵的范数

定义：对任意 n 阶方阵 A ，按一定的规则有一实数与之对应，记为 $\|A\|$ 。若 $\|A\|$ 满足：

- 1 $\|A\| \geq 0$ ，且 $\|A\| = 0$ 当且仅当 $A = 0$ ；（正定）
- 2 $\|\alpha A\| = |\alpha| \cdot \|A\|$ ， α 为任意实数；（齐次）
- 3 $\|A + B\| \leq \|A\| + \|B\|$ ，对任意 A, B 两个 n 阶方阵；（三角不等式）
- 4 $\|AB\| \leq \|A\| \|B\|$ ；（矩阵乘法不等式，相容性条件）

则称 $\|A\|$ 为矩阵 A 的范数

向量和矩阵的范数

- 几种矩阵范数

- 矩阵的“2”范数
(谱范数)

$$\|A\|_2 = \left[\lambda_{\max}(A^T A) \right]^{1/2}$$

- 矩阵的“1”范数
(列和范数)

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

- 矩阵的“ ∞ ”范数
(行和范数)

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

向量和矩阵的范数

- 谱和谱半径

- $A \in R^{n \times n}$ 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$,
- 称 A 的所有特征值的集合为 A 的谱
- 称 $\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$ 为 A 的谱半径

- $\|A\|$ 为 A 的任意一种范数, 有 $\rho(A) \leq \|A\|$

- (按行) 严格对角占优阵

- 如果 A 满足条件

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}| \quad (i = 1, 2, \dots, n)$$

即 A 的每一行对角元素的绝对值都严格大于同行其他元素绝对值之和

病态方程组和矩阵条件数

● 例:

$$\begin{bmatrix} 1 & 0.99 \\ 0.99 & 0.98 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.99 \\ 1.97 \end{bmatrix} \quad x = (1, 1)^T$$

● 若系数矩阵有微小扰动

$$\Delta A = \begin{bmatrix} 0.0001 & 0 \\ 0 & 0 \end{bmatrix}$$

$$\frac{\|\Delta A\|_\infty}{\|A\|_\infty} = 5 \times 10^{-5}$$

● 则

$$\begin{bmatrix} 1.0001 & 0.99 \\ 0.99 & 0.98 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.99 \\ 1.97 \end{bmatrix} \Rightarrow \tilde{x}^{(1)} = (50, -48.5)^T$$

$$\frac{\|\Delta x^{(1)}\|_\infty}{\|x\|_\infty} = 49.5$$

● 若右端有微小扰动

$$\Delta b = \begin{bmatrix} -0.0001 \\ 0.0001 \end{bmatrix}$$

$$\frac{\|\Delta b\|_\infty}{\|b\|_\infty} = 5 \times 10^{-5}$$

● 则

$$\begin{bmatrix} 1 & 0.99 \\ 0.99 & 0.98 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.9899 \\ 1.9701 \end{bmatrix} \Rightarrow \tilde{x}^{(2)} = (2.97, -0.99)^T$$

$$\frac{\|\Delta x^{(2)}\|_\infty}{\|x\|_\infty} = 1.99$$

● 若同时对系数矩阵和右端有扰动, 则

$$\begin{bmatrix} 1.0001 & 0.99 \\ 0.99 & 0.98 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.9899 \\ 1.9701 \end{bmatrix} \Rightarrow \tilde{x}^{(3)} = (148.5, -148.005)^T$$

$$\frac{\|\Delta x^{(3)}\|_\infty}{\|x\|_\infty} = 149.005$$

病态方程组和矩阵条件数

- 扰动方程 $(A + \Delta A)x = b + \Delta b$
- 如果方程组的系数或常数项有微小改变时，解会发生很大的改变，则称这种方程组为“**病态**”的
- 扰动方程的解与原方程的解相对误差不大，称为**良态**方程
- 方程组的“**条件**”问题
- 一般说来，在用计算机解方程组时，实际上解的都是扰动方程，这是由于计算过程中不可避免地会产生舍入误差
- 对于良态问题，只要数值方法是稳定的，就可以得到较好的结果
- 而对于病态问题，即使算法是稳定的，其计算结果有时也会很坏

扰动方程组的误差界

$$\|AB\| \leq \|A\| \|B\|$$

- b 的扰动

$$A(x + \Delta x) = b + \Delta b \Rightarrow \Delta x = A^{-1} \Delta b$$

$$\Downarrow$$
$$\|\Delta x\| \leq \|A^{-1}\| \|\Delta b\|$$

$$\|b\| = \|Ax\| \leq \|A\| \|x\| \Rightarrow \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}$$

$$\left. \begin{array}{l} \|\Delta x\| \leq \|A^{-1}\| \|\Delta b\| \\ \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|} \end{array} \right\} \Rightarrow \frac{\|\Delta x\|}{\|x\|} \leq \|A\| \|A^{-1}\| \frac{\|\Delta b\|}{\|b\|}$$

- A 的扰动

$$(A + \Delta A)(x + \Delta x) = b \Rightarrow \Delta x = -A^{-1} \Delta A (x + \Delta x) \Rightarrow \frac{\|\Delta x\|}{\|x + \Delta x\|} \leq \|A\| \|A^{-1}\| \frac{\|\Delta A\|}{\|A\|}$$

- 同时扰动

$$(A + \Delta A)(x + \Delta x) = b + \Delta b$$

$$\|A^{-1}\| \|\Delta A\| \leq 1$$

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|} \right)$$

病态方程组和矩阵条件数

- 条件数

- 设 $A \in R^{n \times n}$, 非奇异, $\text{Cond}(A) = \|A\| \|A^{-1}\|$

- $K(A) = \|A\|_2 \|A^{-1}\|_2$ 称为谱条件数

- 条件数的性质

- 对任何非奇异矩阵 A , 有 $\text{Cond}(A) \geq 1$ 。

- 对任何非奇异矩阵 A , 非零常数 c , 有 $\text{Cond}(cA) = \text{Cond}(A)$

- 若 P 为正交矩阵, 则 $K(P) = 1$, 且 $K(PA) = K(AP) = K(A)$

- 若 $A = A^T$,

$$K(A) = \frac{|\lambda_{\max}(A)|}{|\lambda_{\min}(A)|}$$

病态方程组和矩阵条件数

- 线性方程组 $Ax=b$ 解的相对误差直接与 A 的条件数相关
- A 的条件数 $\text{Cond}(A)$ 相对大($\gg 1$), 称 $Ax=b$ 是病态方程组/坏条件, 或 A 是病态的; 当 A 的条件数 $\text{Cond}(A)$ 相对小, 称 $Ax=b$ 是良态方程组/好条件, 或 A 是良态的。

$$A = \begin{bmatrix} 1 & 0.99 \\ 0.99 & 0.98 \end{bmatrix}$$

$$\text{cond}(A)_2 = K(A) = \frac{|\lambda_{\max}|}{|\lambda_{\min}|} = \frac{1.98005}{0.00005} = 39206 \gg 1$$

方程是病态方程

矩阵条件数

- Hilbert矩阵是一个著名的病态矩阵，它是一个对称正定矩阵，当 $n \geq 3$ 时，Hilbert矩阵是病态矩阵
- n 越大，条件数越大
- Matlab 中 `hilb()` 构造 hilbert 矩阵，`invhilb()`可求精确逆

$$A = \begin{bmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \cdots & \frac{1}{n+1} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \cdots & \frac{1}{n+2} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \frac{1}{n} & \frac{1}{n+1} & \frac{1}{n+2} & \cdots & \frac{1}{2n-1} \end{bmatrix}$$

相对误差的事后估计（近似解可靠性判别）

- 设 $Ax=b$ ， A 为非奇异矩阵， x 为精确解， \tilde{x} 为计算解，残差向量 $r=b-A\tilde{x}$
- 则近似解的相对误差估计

$$\frac{1}{\text{cond}(A)} \frac{\|r(\tilde{x})\|}{\|b\|} \leq \frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|r(\tilde{x})\|}{\|b\|}$$

- $\text{Cond}(A)$ 越小，相对误差越小
- 近似解的精度不仅依赖于残差向量 r ，也与矩阵 A 的条件数有关

相对误差的事后估计

$$A = \begin{bmatrix} 6 & 13 & -17 \\ 13 & 29 & -38 \\ -17 & -38 & 50 \end{bmatrix} \quad A^{-1} = \begin{bmatrix} 6 & -4 & -1 \\ -4 & 11 & 7 \\ -1 & 7 & 5 \end{bmatrix}$$

$$\text{cond}(A)_{\infty} = \|A\|_{\infty} \|A^{-1}\|_{\infty} = 105 \times 22 = 2310$$

- 假定在求解 $Ax=b$ 的过程中，得到的解满足

$$\|r\| \leq 0.001$$

- 绝对误差上界

$$\|\Delta x\| \leq \|A^{-1}\| \|r\| \leq 22 \times 0.001 = 0.022$$

- 若给定 $\|b\|=4$ ，相对误差上界

$$\frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|r(\tilde{x})\|}{\|b\|} \leq 2310 \times \frac{0.001}{4} = 0.5775$$

病态方程组的判别

- 当 A 的行列式值相对小，或 A 某些行/列近似线性相关，方程组可能病态
- 若用选主元消去法求解 $Ax=b$ ，在 A 消去中出现小主元，方程组可能病态
- 当 A 元素数量级相差很大且无一定规则，方程组可能病态
- 估计条件数，若条件数较大，则方程组病态

迭代求精技术

- 设 x 为精确解, \tilde{x}_1 为得到的近似解, 则
- 残差向量

$$r_1 = b - A\tilde{x}_1$$



$$A\Delta x_1 = r_1$$

$$x = \tilde{x}_1 + \Delta x_1$$



$$Ax = A\tilde{x}_1 + A\Delta x_1$$


- 通过求解上述方程, 可以得到修正因子 Δx_1
- 由于舍入误差的影响, 同样 $\tilde{x}_2 = \tilde{x}_1 + \Delta x_1$ 不会是精确解, 可从 \tilde{x}_2 出发重复以上步骤
- 对于LU分解, 只需计算残差向量再进行回代
- 当 $Ax=b$ 不过分病态时, 迭代求精是较成功的提高近似解精度的方法

本章内容

- 高斯消去法
- LU分解、特殊矩阵和矩阵求逆
- 误差分析、条件数
- 迭代方法

迭代法的思想

$$\begin{aligned}a_{11}x_1 + a_{12}x_2 + a_{13}x_3 &= c_1 \\a_{21}x_1 + a_{22}x_2 + a_{23}x_3 &= c_2 \\a_{31}x_1 + a_{32}x_2 + a_{33}x_3 &= c_3\end{aligned}$$



$$\begin{aligned}x_1 &= \frac{c_1 - a_{12}x_2 - a_{13}x_3}{a_{11}} \\x_2 &= \frac{c_2 - a_{21}x_1 - a_{23}x_3}{a_{22}} \\x_3 &= \frac{c_3 - a_{31}x_1 - a_{32}x_2}{a_{33}}\end{aligned}$$

高斯-赛得尔方法
(异步迭代法)

First Iteration

$$\begin{aligned}x_1 &= (c_1 - a_{12}x_2 - a_{13}x_3)/a_{11} \\x_2 &= (c_2 - a_{21}x_1 - a_{23}x_3)/a_{22} \\x_3 &= (c_3 - a_{31}x_1 - a_{32}x_2)/a_{33}\end{aligned}$$

Second Iteration

$$\begin{aligned}x_1 &= (c_1 - a_{12}x_2 - a_{13}x_3)/a_{11} \\x_2 &= (c_2 - a_{21}x_1 - a_{23}x_3)/a_{22} \\x_3 &= (c_3 - a_{31}x_1 - a_{32}x_2)/a_{33}\end{aligned}$$

(a)

First Iteration

$$\begin{aligned}x_1 &= (c_1 - a_{12}x_2 - a_{13}x_3)/a_{11} \\x_2 &= (c_2 - a_{21}x_1 - a_{23}x_3)/a_{22} \\x_3 &= (c_3 - a_{31}x_1 - a_{32}x_2)/a_{33}\end{aligned}$$

Second Iteration

$$\begin{aligned}x_1 &= (c_1 - a_{12}x_2 - a_{13}x_3)/a_{11} \\x_2 &= (c_2 - a_{21}x_1 - a_{23}x_3)/a_{22} \\x_3 &= (c_3 - a_{31}x_1 - a_{32}x_2)/a_{33}\end{aligned}$$

(b)

雅可比方法
(同步迭代法)

迭代法

$$Ax = b \implies x = Gx + f$$

- 任取初始向量 $x^{(0)}$ ，作

$$x^{(1)} = Gx^{(0)} + f$$

$$x^{(k+1)} = Gx^{(k)} + f$$

- 构造向量序列 $\{x^{(k)}\}$ 求方程的近似解的方法，称为一阶定常迭代法， G 为该迭代法的迭代矩阵。
- 如果对任意取初始近似 $x^{(0)}$ ，都有 $\lim_{k \rightarrow \infty} x^{(k)} = x^*$ ，称迭代法为**收敛**，否则称迭代法为**发散**。若迭代法收敛，则称 $x^{(k)}$ 为第 k 步迭代得到方程组的近似解。

迭代法

- 问题
 - 构造迭代方法
 - 迭代的收敛性和收敛速度

基本迭代方法

- A 分裂为 $A=M-N$
- 分裂阵 M
 - 可选择非奇异阵
 - $Mx=d$ 易于求解
 - M 选为 A 的某种近似
- $Ax=b \quad Mx=Nx+b \quad x=M^{-1}Nx+M^{-1}b$
- 迭代：
 - $x^{(0)}$ 为初始向量
 - $x^{(k+1)}=M^{-1}Nx+M^{-1}b$
- 选取不同的 M 阵就得到不同迭代法。

$$A = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} - \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \vdots & \ddots & \\ -a_{n1} & -a_{n2} & \cdots & 0 \end{bmatrix} - \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ & 0 & \cdots & -a_{2n} \\ & & \ddots & \vdots \\ & & & 0 \end{bmatrix} = D - L - U$$

雅可比(Jacobi)迭代法（同步迭代法）

- 设A为非奇异矩阵，且 $a_{ii} \neq 0$ ，选取 $M=D$ 和 $N=D-A=L+U$
- $x^{(k+1)} = Jx^{(k)} + f$ $J = D^{-1}(L+U)$ $f = D^{-1}b$

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \cdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \cdots \\ b_n \end{bmatrix} \Rightarrow \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \cdots & \\ & & & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \cdots \\ x_n \end{bmatrix} = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ -a_{21} & 0 & \cdots & -a_{2n} \\ \cdots & \cdots & \cdots & \cdots \\ -a_{n1} & -a_{n2} & \cdots & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \cdots \\ x_n \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ \cdots \\ b_n \end{bmatrix}$$

(1)雅可比迭代法，每迭代一次主要是计算一次矩阵乘向量，即 $Jx^{(k)}$ 。

(2)计算过程中，原始数据A始终不变。

(3)计算中需要两组工作单元来保存 $x^{(k)}$ 及 $x^{(k+1)}$ 。

$$\begin{bmatrix} x_1^{(k+1)} \\ x_2^{(k+1)} \\ \vdots \\ x_n^{(k+1)} \end{bmatrix} = \begin{bmatrix} 0 & -\frac{a_{12}}{a_{11}} & \cdots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & \cdots & -\frac{a_{2n}}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & \cdots & \cdots & 0 \end{bmatrix} \begin{bmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{bmatrix} + \begin{bmatrix} \frac{b_1}{a_{11}} \\ \frac{b_2}{a_{22}} \\ \vdots \\ \frac{b_n}{a_{nn}} \end{bmatrix}$$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)} \right)$$

高斯-赛德尔(Gauss-Seidel)迭代法（异步迭代法）

- 选取 $M=D-L$ 和 $N=M-A=U$
- $x^{(k+1)}=Gx^{(k)}+f$ $G=(D-L)^{-1}U$ $f=(D-L)^{-1}b$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

(1)G-S迭代法每迭代一次主要是计算一次矩阵乘向量。

(2)计算 $x^{(k+1)}$ 的第 i 个分量 $x_i^{(k+1)}$ 时，利用已计算出的最新分量 $x_j^{(k+1)}(j=1,\dots,i-1)$ ，因此，计算中只需要一组工作单元来保存 $x^{(k)}$ 或 $x^{(k+1)}$ 。

迭代终止准则

- 近似相对百分误差

$$|\varepsilon_a|_i = \left| \frac{x_i^{(k+1)} - x_i^{(k)}}{x_i^{(k+1)}} \right| \times 100$$

- 对所有的 i ，近似相对百分误差小于预设的 ε_s 时，迭代终止
- 其他的终止准则

$$\frac{\|x^{(k+1)} - x^{(k)}\|}{\|x^{(k+1)}\|}$$

迭代法——例

- 求解线性代数方程组

$$\begin{bmatrix} 10 & -2 & -1 \\ -2 & 10 & -1 \\ -1 & -2 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ 15 \\ 10 \end{bmatrix}$$

- Jacobi迭代

$$J = \begin{bmatrix} 0 & 0.2 & 0.1 \\ 0.2 & 0 & 0.1 \\ 0.2 & 0.4 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 & 0.2 & 0.1 \\ 0.2 & 0 & 0.1 \\ 0.2 & 0.4 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} + \begin{bmatrix} 0.3 \\ 1.5 \\ 2 \end{bmatrix}$$

$$\begin{cases} x_1^{(k+1)} = 0.2x_2^{(k)} + 0.1x_3^{(k)} + 0.3 \\ x_2^{(k+1)} = 0.2x_1^{(k)} + 0.1x_3^{(k)} + 1.5 \\ x_3^{(k+1)} = 0.2x_1^{(k)} + 0.4x_2^{(k)} + 2 \end{cases}$$

- G-S迭代

$$\begin{cases} x_1^{(k+1)} = 0.2x_2^{(k)} + 0.1x_3^{(k)} + 0.3 \\ x_2^{(k+1)} = 0.2x_1^{(k+1)} + 0.1x_3^{(k)} + 1.5 \\ x_3^{(k+1)} = 0.2x_1^{(k+1)} + 0.4x_2^{(k+1)} + 2 \end{cases}$$

迭代法——例

G-S方法比Jacobi方法收敛快。

迭代次数	Jacobi方法						G-S方法					
	x_1	$ \varepsilon_a _1$	x_2	$ \varepsilon_a _2$	x_3	$ \varepsilon_a _3$	x_1	$ \varepsilon_a _1$	x_2	$ \varepsilon_a _2$	x_3	$ \varepsilon_a _3$
0	0		0		0		0		0		0	
1	0.3	100	1.5	100	2	100	0.3	100	1.56	100	2.684	100
2	0.8	62.5	1.76	14.7727	2.66	24.812	0.8804	65.9246	1.9445	19.7729	2.9539	9.1362
3	0.918	12.854	1.926	8.6189	2.864	7.1229	0.9843	10.5542	1.9922	2.3975	2.9938	1.3322
4	0.9716	5.5167	1.97	2.2335	2.954	3.0467	0.9997	1.3571	1.9989	0.335	2.9991	0.1796
5	0.9894	1.7991	1.9897	0.9911	2.9823	0.9496	1	0.1879	1.9999	0.0457	2.9999	0.0247
6	0.9962	0.6802	1.9961	0.3202	2.9938	0.3824	1	0.0257	2	0.0063	3	0.0034
7	0.9986	9.2427	1.9986	0.1251	2.9977	0.1305	1	0.0035	2	0.0009	3	0.0005
8	0.9995	0.0892	1.9995	0.0438	2.9992	0.0495						
9	0.9998	0.0324	1.9998	0.0163	2.9997	0.0176						
10	0.9999	0.0118	1.9999	0.0059	2.9999	0.0065						

迭代法的收敛性

- $x=Gx+f$ $x^*=Gx^*+f$
- 迭代 $x^{(k+1)}=Gx^{(k)}+f$
- 引入误差向量 $e^{(k)}=x^{(k)}-x^*$
- 误差向量的递推公式: $e^{(k+1)}=Ge^{(k)}$
- 于是 $e^{(k)}=Ge^{(k-1)}=G^2e^{(k-2)}=\dots=G^ke^{(0)}$ ($e^{(0)}=x^{(0)}-x^{(*)}$)

$$\|e^{(k)}\| = \|G^k e^{(0)}\| \leq \|G\|^k \|e^{(0)}\| = q^k \|e^{(0)}\|$$

- 定理: 设 $G \in R^{n \times n}$, 则 $G^k \rightarrow 0$ (零矩阵) (当 $k \rightarrow \infty$ 时) 的充要条件为 G 所有特征值满足 $|\lambda_i| < 1$ ($i=1, 2, \dots, n$) 或 G 的谱半径 $\rho(G) < 1$

迭代法的收敛性

- 一阶定常迭代法收敛性的基本定理

- 设有方程组 $x=Gx+f$ ，有迭代法 $x^{(k+1)}=Gx^{(k)}+f$ ，则对任选初始向量 $x^{(0)}$ ，迭代法收敛的充要条件是 $\rho(G)<1$ 。

- 迭代收敛的充分条件

- 设有方程组 $x=Gx+f$ 及一阶定常迭代法 $x^{(k+1)}=Gx^{(k)}+f$ ，如果有 G 的某种范数 $\|G\|_r=q<1$ ，则

- 迭代法收敛；

- 误差估计

$$\|x^* - x^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\| < \frac{1}{1-q} \|x^{(k)} - x^{(k-1)}\|$$

事后估计

$$\|x^* - x^{(k)}\| \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|$$

事前估计

- 当 $q \approx 1$ 时，迭代法收敛缓慢。

q 越小收敛速度越快；可以事先估计保证误差 $\|x^* - x^{(k)}\|_\infty < \varepsilon$ 所需要的迭代次数。

迭代法的收敛性

matlab中计算特征值: eig()

- 推论:

- Jacobi迭代法收敛的充要条件是 $\rho(J) < 1$ ($J = D^{-1}(L+U)$)
- G-S迭代法收敛的充要条件是 $\rho(G) < 1$ ($G = (D-L)^{-1}U$)

- 例1:

$$A = \begin{bmatrix} 1 & 0.8 & 0.8 \\ 0.8 & 1 & 0.8 \\ 0.8 & 0.8 & 1 \end{bmatrix} \quad J = \begin{bmatrix} 0 & -0.8 & -0.8 \\ -0.8 & 0 & -0.8 \\ -0.8 & -0.8 & 0 \end{bmatrix}$$

$\rho(J) = 1.6 > 1$ Jacobi迭代不收敛

$$G = \begin{bmatrix} 1 & 0 & 0 \\ 0.8 & 1 & 0 \\ 0.8 & 0.8 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 0 & -0.8 & -0.8 \\ 0 & 0 & -0.8 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -0.8 & -0.8 \\ 0 & 0.64 & -0.16 \\ 0 & 0.128 & 0.768 \end{bmatrix}$$

$\rho(G) < 1$ G-S迭代收敛

- 例2:

$$A = \begin{bmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{bmatrix} \quad J = \begin{bmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{bmatrix}$$

$\rho(J) < 1$ Jacobi迭代收敛

$$G = \begin{bmatrix} 0 & -2 & 2 \\ 0 & 2 & -3 \\ 0 & 0 & 2 \end{bmatrix}$$

$\rho(G) > 1$ G-S迭代不收敛

对于给定的线性方程组, 用雅可比法和G-S法求解时可能都收敛或都不收敛, 也可能一个收敛另一个不收敛。

迭代法的收敛性

- 如果 A 为（按行或列）严格对角占优阵，则 $Ax=b$ 的Jacobi方法和G-S方法都收敛。
 - 实际上，如果 A 为严格对角占优阵，可以证明， $\|J\|_{\infty} < 1$ 并且 $\|G\|_{\infty} < 1$ ，因此，Jacobi方法和G-S方法都收敛。
 - G-S迭代法比Jacobi迭代法收敛得快
- 如果 A 为对称正定矩阵，G-S迭代收敛。
- 例：判断解 $Ax=b$ 的Jacobi方法和G-S方法的收敛性

$$A = \begin{bmatrix} 10 & -2 & -1 \\ -2 & 10 & -1 \\ -1 & -2 & 5 \end{bmatrix}$$

$$|a_{11}| = 10 > |-2| + |-1|$$

$$|a_{22}| = 10 > |-2| + |-1|$$

$$|a_{33}| = 5 > |-1| + |-2|$$

A 是严格对角占优矩阵，两种方法都收敛

迭代法的收敛性

- 例：用G-S方法求解

$$\begin{aligned} 3x_1 + 7x_2 + 13x_3 &= 76 \\ x_1 + 5x_2 + 3x_3 &= 28 \\ 12x_1 + 3x_2 - 5x_3 &= 1 \end{aligned}$$

不收敛！

Iteration	x_1	$ \varepsilon_a _1$	x_2	$ \varepsilon_a _2$	x_3	$ \varepsilon_a _3$
1	21.000	110.71	0.80000	100.00	5.0680	98.027
2	-196.15	109.83	14.421	94.453	-462.30	110.96
3	-1995.0	109.90	-116.02	112.43	4718.1	109.80
4	-20149	109.89	1204.6	109.63	-47636	109.90
5	2.0364×10^5	109.90	-12140	109.92	4.8144×10^5	109.89
6	-2.0579×10^5	1.0990	1.2272×10^5	109.89	-4.8653×10^6	109.89

$$[A] = \begin{bmatrix} 3 & 7 & 13 \\ 1 & 5 & 3 \\ 12 & 3 & -5 \end{bmatrix}$$



$$[A] = \begin{bmatrix} 12 & 3 & -5 \\ 1 & 5 & 3 \\ 3 & 7 & 13 \end{bmatrix}$$

不是所有的矩阵都可以通过重排变为严格对角占优阵

$$\begin{aligned} x_1 + x_2 + x_3 &= 3 \\ 2x_1 + 3x_2 + 4x_3 &= 9 \\ x_1 + 7x_2 + x_3 &= 9 \end{aligned}$$

逐次超松弛迭代法(SOR, Successive Over-Relaxation)

$$\tilde{x}_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$

G-S方法得到的解

- 高斯-赛得尔方法的基础上进行修改

- $$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \omega\tilde{x}_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right)$$
 $0 < \omega < 2$, 称为松弛因子

- $\omega=1$, SOR方法即为G-S方法
- $0 < \omega < 1$, 结果为当前迭代结果和上一次迭代结果的加权平均, 称为低松弛方法。用于使得非收敛方程组收敛或者克服振荡加速收敛。
- $1 < \omega < 2$, 超松弛方法
 - 隐含假设: 新值沿正确方向向真实解移动, 但是移动的速度慢
 - 用于加速已知是收敛的方程组的收敛速度
 - 根据经验确定 ω 值

SOR——例

$$\begin{bmatrix} -4 & 1 & 1 & 1 \\ 1 & -4 & 1 & 1 \\ 1 & 1 & -4 & 1 \\ 1 & 1 & 1 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

精确解为 $x^* = [-1 \ -1 \ -1 \ -1]^T$ ，初始向量 $x^{(0)} = [0 \ 0 \ 0 \ 0]^T$

松弛因子	满足 $\ x^{(k)} - x^*\ < 10^{-5}$ 的迭代次数
1.0	22
1.1	17
1.2	12
1.3	11
1.4	14
1.5	17
1.6	23
1.7	33
1.8	53
1.9	107

最佳松弛因子

SOR——收敛性

- SOR的矩阵形式

$$x_i^{(k+1)} = x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i}^n a_{ij} x_j^{(k)} \right)$$

$$M = (D - \omega L) / \omega$$



$$(D - \omega L)x^{(k+1)} = [(1 - \omega)D + \omega U]x^{(k)} + \omega b$$



$$x^{(k+1)} = G\omega x^{(k)} + f$$

$$G\omega = (D - \omega L)^{-1} [(1 - \omega)D + \omega U]$$

$$f = \omega(D - \omega L)^{-1} b$$

- SOR法收敛的充要条件是 $\rho(G\omega) < 1$
- 如果 A 为对称正定阵，且 $0 < \omega < 2$ ，则解 $Ax = b$ 的SOR法收敛。

MATLAB中的函数

矩阵分析		线性方程组	
函数	描述	函数	描述
cond	计算矩阵条件数	右除/和左除\	help slash
norm	计算矩阵或向量的范数	lu	lu分解
inv	矩阵求逆	chol	cholesky分解
pinv	求矩阵伪逆		
det	计算行列式的值		
rank	求秩		
eig, eigs	矩阵特征值		

第三章 总结——各种方法

方法	稳定性	精度	应用范围	编程难度	备注
图解法	—	差	受限	—	比数值方法耗时
Cramer法则	—	受舍入误差影响	受限	—	方程数多于3个时计算复杂
列主元高斯消去	—	受舍入误差影响	一般，适用于方程组系数矩阵为低阶稠密矩阵、带状矩阵	中等，计算量较小，存储量较大	
LU分解					常用；进行矩阵求逆计算
迭代法 (Jacobi和G-S)	可能不收敛	优秀	收敛时，适用于大型稀疏线性方程组	较简单，计算量有时较大，存储量较小	

第三章 总结——重要内容

- 直接法
 - 高斯消去、LU分解
- 迭代
 - Jacobi、Gauss-Seidel、SOR
- 具体算法、问题及改进
- 范数、条件数、病态方程组